

Wprowadzenie do głębokich architektur sieci neuronowych


Perceptron

Wykład nr 1


dr Mateusz Draga

Zakład Hydrobiologii

matdra@amu.edu.pl



- Koncepcja neuronu (Neuron McCullocha-Pittsa) - 1943



- Propozycja perceptronu (Frank Rosenblatt) - 1957


Perceptron



Wydział
Biologii

input

output




dane wejściowe

dane wyjściowe

Perceptron




Wydział
Biologii



Perceptron





Wydział
Biologii



Perceptron





Wydział
Biologii



Perceptron




Wydział
Biologii



Perceptron




Wydział
Biologii



**Podobieństwa między
perceptronem oraz neuronem:**

- Dane wejściowe z kilku źródeł
- Jeden wynik
- Aktywacja powyżej pewnego progu pobudzenia



Perceptron




Wydział
Biologii



Dane wejściowe: wartości liczbowe wejściowe.
W oryginalnym perceptronie przyjmowały
wartości binarne.

1. Dane wejściowe pochodzący
z n wejść (input)




Perceptron



Wydział
Biologii

Wagi danych wejściowych: “istotność” dla modelu danych z danego węzła. Im większa waga, tym większy wpływ na wynik. Pozytywne wagi zwiększają szanse na aktywację, negatywne zmniejszają.

2



1. Dane wejściowe pochodzący z n wejść (input)


2. Wagi danych wejściowych

Perceptron



Wydział
Biologii

Sumowanie wartości danych wejściowych: zanim perceptron “zadecyduje” czy się aktywować, musi zsumować przemnożone przez odpowiednie wagi dane wejściowe. Wynik takiej sumy trafia do funkcji aktywacji




1. **Dane wejściowe** pochodzący z n wejść (input)
2. **Wagi danych wejściowych**
3. **Suma** danych wejściowych przemnożonych przez **wagi**

Perceptron



Wydział
Biologii

Funkcja aktywacji: decyduje o wyniku danego perceptronu. Wykonuje operację na otrzymanej w poprzednim kroku sumie. Operacja zależy od zastosowanej funkcji aktywacji. W tym wypadku wykorzystujemy funkcję progową. Zwraca 0 lub 1.




1. **Dane wejściowe** pochodzący z n wejść (input)
2. **Wagi danych wejściowych**
3. **Suma** danych wejściowych przemnożonych przez **wagi**
4. **Funkcja Aktywacji**

Perceptron




Wydział
Biologii

Wynik przyjmujący wartości 0 lub 1.



1. Dane wejściowe pochodzący z n wejść (input)
2. Wagi danych wejściowych
3. Suma danych wejściowych przemnożonych przez wagi
4. Funkcja Aktywacji
5. Wynik (output)



funkcja aktywacji

$$y = f \left(bias + \sum_{i=1}^n x_i w_i \right)$$

$$\sum_{i=1}^n x_i w_i$$


suma przemnożonych przez wagi wszystkich danych wejściowych

bias

“przesunięcie” funkcji - wartość progowa.

f()

Wykorzystywana funkcja. W wypadku perceptronu wykorzystujemy **funkcję progową** (threshold function)



funkcja aktywacji

$$y = f \left(bias + \sum_{i=1}^n x_i w_i \right)$$

funkcja progowa


$$f() \quad f(x) = \begin{cases} 0 & \text{dla } x < 0 \\ 1 & \text{dla } x \geq 0 \end{cases}$$


Bardzo prosty typ **funkcji aktywacji**. Daje wynik 1 dla wartości równych lub większych niż zero oraz wynik 0 dla wartości mniejszych niż zero.

Przykład



Wydział
Biologii






Problem liniowej separowalności danych



Wydział
Biologii




W przestrzeni 2d (dla 2 węzłów wejścia) perceptron dokonuje w zasadzie klasyfikacji liniowej.

W zależności od wartości wag oraz bias'u **funkcja aktywacji** rozdziela przestrzeń na **dwie części**: jedną dającą wyniki 0 i drugą dającą wynik 1. Tworzona jest hiperpłaszczyzna decyzyjna.

Pojawia się problem - co robić gdy przypadki nie są separowalne przez linie prostą?

Problem liniowej separowalności danych




W przestrzeni 2d (dla 2 węzłów wejścia) perceptron dokonuje w zasadzie klasyfikacji liniowej.

W zależności od wartości wag oraz bias'u **funkcja aktywacji** rozdziela przestrzeń na **dwie części**: jedną dającą wyniki 0 i drugą dającą wynik 1. Tworzona jest hiperpłaszczyzna decyzyjna.

Pojawia się problem - co robić gdy przypadki nie są separowalne przez linię prostą?

Rozważmy teraz przypadek perceptronu, który przejmuje dane z 2 węzłów, dla których posiada wagi równe -2 oraz bias równy 3.




A	B	Output
0	0	1
1	0	1
0	1	1
1	1	0

Problem liniowej separowalności danych




Wydział
Biologii


NAND Gate Symbol




NOT Gate
(Inverter)




AND Gate




Buffer




OR Gate




Exclusive-OR




NOR Gate



Exclusive-NOR



Rozważmy teraz przypadek perceptronu, który przejmuje dane z 2 węzłów, dla których posiada wagi równe -2 oraz bias równy 3.




A	B	Output
0	0	1
1	0	1
0	1	1
1	1	0

Jak widzimy, bramkę NAND możemy naśladować wykorzystując pojedynczy perceptron. Wykorzystując następnie same bramki NAND możemy naśladować wszystkie inne kluczowe bramki logiczne.

Perceptron - jak się uczy?



Wydział
Biologii




Jak wytrenować perceptron?

1. Nadaj losowe wartości **wagom** oraz **bias'owi** i ustal **learning rate**.
2. Policz wynik losowo ustawionego perceptronu.
3. Policz o ile pomylił się perceptron w obliczeniu.
4. Korzystając z poniższych wzorów cofnij się i popraw wagi oraz bias.
5. Powtarzaj ***n*** razy...

Perceptron - jak się uczy?



Wydział
Biologii



Jak wytrenować perceptron?


1. Nadaj losowe wartości **wagom** oraz **bias'owi** i ustal **learning rate**.
2. Policz wynik losowo ustawionego perceptronu.
3. Policz o ile pomylił się perceptron w obliczeniu.
4. Korzystając z poniższych wzorów cofnij się i popraw wagi oraz bias.
5. Powtarzaj ***n*** razy...

$$\left. \begin{aligned} w_i &:= w_i + \eta (y - \hat{y}) \times x_i \\ b &:= b + \eta (y - \hat{y}) \end{aligned} \right\}$$

Perceptron - jak się uczy?



Wydział
Biologii




Jak wytrenować perceptron?

1. Nadaj losowe wartości **wagom** oraz **bias'owi** i ustal **learning rate**.
2. Policz wynik losowo ustawionego perceptronu.
3. Policz o ile pomylił się perceptron w obliczeniu.
4. Korzystając z poniższych wzorów cofnij się i popraw wagi oraz bias.
5. Powtarzaj ***n*** razy...

$$w_i := w_i + \eta (y - \hat{y}) \times x_i$$

$$b := b + \eta (y - \hat{y})$$



y

- Właściwy wynik

x_i

- Input nr i

$\hat{y}$

- Predykcja

w_i

- Waga nr i


η

- Learning rate

b

- bias

Przykład



Jak wytrenować perceptron?

1. Nadaj losowe wartości **wagom** oraz **bias'owi** i ustal **learning rate**.
2. Policz wynik losowo ustawionego perceptronu.
3. Policz o ile pomylił się perceptron w obliczeniu.
4. Korzystając z poniższych wzorów cofnij się i popraw wagi oraz bias.
5. Powtarzaj ***n*** razy...

$$\left. \begin{aligned} w_i &:= w_i + \eta (y - \hat{y}) \times x_i \\ b &:= b + \eta (y - \hat{y}) \end{aligned} \right\}$$

Niech:

$$x = (2, 1), w = (0.5, -0.5), \\ b = 0, \eta = 0.1, y = 1, \hat{y} = 0$$