



Wydział
Biologii

Wprowadzenie do głębokich architektur sieci neuronowych


Sieci konwolucyjne CNN

Wykład nr 4

dr Mateusz Draga


Zakład Hydrobiologii

matdra@amu.edu.pl






Lemna minor




*Lemna minor z ręcznie zaznaczonymi
pikselami do analizy*







Wartości liczbowe kanałów RGB dla tła (class 1) i dla *L. minor* (class 2)




Red



Green



Blue



Color Chart	R	G	B	Color Name
	0	0	0	Black
	255	255	255	White
	224	224	224	Light Gray
	128	128	128	Gray
	64	64	64	Dark Gray
	255	0	0	Red
	255	96	208	Pink
	160	32	255	Purple
	80	208	255	Light Blue
	0	32	255	Blue
	96	255	128	Yellow-Green
	0	192	0	Green
	255	224	32	Yellow
	255	160	16	Orange
	160	128	96	Brown
	255	208	160	Pale Pink

Przykładowe barwy kolorów zapisanych w formacie RGB.

<https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>

<https://poloclub.github.io/cnn-explainer/>

Czemu nie zwykła głęboka sieć?



Wydział
Biologii

Wyobraźmy sobie, że pracujemy z prostym kolorowym obrazem, wielkości 244 x 244.

Jeśli chcielibyśmy zamienić go na wektor inputu dla naszej sieci to input miałby prawie 200 tyś. danych wejściowych na obraz! (244 x 244 x 3).

Dodatkowo, przy takiej strukturze inputu tracimy informacje o wzajemnym położeniu pikseli.




244 x 244


Czym jest sieć CNN



Wydział
Biologii



Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło:
Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026



Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło: Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026

Sieć typu CNN (Convolutional Neural Network, konwolucyjna sieć neuronowa) to rodzaj sieci neuronowej zaprojektowanej głównie do analizy danych obrazowych i przestrzennych. Wykorzystuje operacje konwolucji do automatycznego wykrywania cech, takich jak krawędzie, kształty czy obiekty na obrazie.


Jej głównym celem jest rozpoznawanie i klasyfikacja wzorców w danych, np. identyfikacja obiektów na zdjęciach, analiza obrazów medycznych, rozpoznawanie twarzy czy przetwarzanie wideo.

CNN składa się z warstw konwolucyjnych wykorzystujących kernela (filtry) oraz warstw głębokiej sieci neuronowej.

Schemat CNN:

1. Macierz obrazu wejściowego
2. Convolutional Layer (filtr Kernel)
3. Funkcja aktywacji
4. Pooling layer
5. Flatten Layer
6. Fully Connected Layer (klasyfikacja)
7. Output

W praktyce kroki 2-4 często powtarzają się wielokrotnie w jednej sieci CNN.



Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło: Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026

Convolutional Layer



Wydział
Biologii

Kernel (filtr konwolucyjny) to mała macierz wag przesuwana po obrazie w celu wykrywania charakterystycznych cech, takich jak krawędzie, tekstury czy kształty.

Projektując kernele musimy wybrać następujące parametry:

- **Stride** (określa, o ile pikseli kernel przesuwa się po obrazie podczas konwolucji.)
- **Padding** (dodawanie dodatkowych pikseli (zwykle zer) wokół obrazu, aby kontrolować rozmiar wyjścia i sposób obsługi krawędzi.)
- **Depth** (liczba zastosowanych kerneli/filtrów, czyli liczba tworzonych feature maps)

Na początku treningu wartości w kernelach są zazwyczaj inicjalizowane losowo. We wczesnych warstwach kernele uczą się wykrywać proste cechy (krawędzie, linie, tekstury), w głębszych warstwach bardziej złożone wzorce (kształty, obiekty, twarze itd.).

Input		Kernel		Output																	
<table><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>3</td><td>4</td><td>5</td></tr><tr><td>6</td><td>7</td><td>8</td></tr></table>	0	1	2	3	4	5	6	7	8	*	<table><tr><td>0</td><td>1</td></tr><tr><td>2</td><td>3</td></tr></table>	0	1	2	3	=	<table><tr><td>19</td><td>25</td></tr><tr><td>37</td><td>43</td></tr></table>	19	25	37	43
0	1	2																			
3	4	5																			
6	7	8																			
0	1																				
2	3																				
19	25																				
37	43																				

Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) [źródło: Jorgecardete, https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175](https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175), 27.05.2026


$$\begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

Przykładowy kernel do wykrywania krawędzi pionowych.

Convolutional Layer

Kernel działa jednocześnie na wszystkich feature mapach z poprzedniej warstwy. Kernel wykonuje konwolucję na każdej mapie osobno, a następnie sumuje wyniki i dodaje bias, tworząc jedną nową feature map'ę.

Na tak powstałych feature map'ach stosowana jest następnie funkcja aktywacji (ReLU).



Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło:
Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026

Convolutional Layer




Wydział
Biologii

Kernel oraz **padding** bezpośrednio wpływają na rozmiar powstających feature map w sieci CNN.

Podczas konwolucji **kernel** przesuwa się po obrazie wejściowym i tworzy nową mapę cech. Im większy kernel, tym większy obszar obrazu analizuje jednocześnie, co zazwyczaj prowadzi do większego zmniejszenia wymiarów feature mapy. Przykładowo kernel 3×3 redukuje rozmiar obrazu bardziej niż kernel 1×1 .

Padding polega na dodaniu dodatkowych pikseli, najczęściej zer, wokół obrazu wejściowego przed wykonaniem konwolucji. Jego głównym celem jest kontrolowanie rozmiaru feature map oraz zachowanie informacji znajdujących się przy krawędziach obrazu. Bez paddingu rozmiar feature map zmniejsza się po każdej konwolucji, natomiast zastosowanie odpowiedniego paddingu może utrzymać ten sam rozmiar wejścia i wyjścia.



Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło: Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026

$$\begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

Przykładowy kernel do wykrywania krawędzi pionowych.

Pooling layer



Wydział
Biologii


Pooling Layer (warstwa poolingowa) to warstwa w CNN służąca do zmniejszania rozmiaru feature map poprzez wybieranie najważniejszych informacji z lokalnych obszarów.

Najczęściej stosuje się:

- **max pooling** (wybiera największą wartość)
- **average pooling** (oblicza średnią wartość).

Jej główne zadania:

- redukcja liczby danych i obliczeń,
- zmniejszenie ryzyka przeuczenia (overfitting),
- zachowanie najważniejszych cech obrazu.




Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło: Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026

Flatten Layer

Flatten Layer (warstwa spłaszczająca) to warstwa, która przekształca wielowymiarowe feature mapy w jednowymiarowy wektor, aby dane mogły zostać przekazane do warstw w pełni połączonych (Fully Connected Layers). Jest to zazwyczaj ostatni krok przed przejściem do warstw Dense.

- Np. dla wejścia: $7 \times 7 \times 64$ otrzymamy wektor o długości 3136.




Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło: Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026

Fully Connected Layer

Fully Connected Layer (Dense Layer, warstwa w pełni połączona) to część CNN działająca jak klasyczna głęboka sieć neuronowa, w której każdy neuron jest połączony ze wszystkimi neuronami poprzedniej warstwy. Jej zadaniem jest analiza cech wyekstrahowanych przez warstwy konwolucyjne i wykonanie końcowej klasyfikacji.

Na końcu często stosuje się funkcję Softmax, która zamienia wyniki na prawdopodobieństwa przynależności do poszczególnych klas.




Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło: Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026

Jak przygotować dane przed CNN

Przygotowanie danych tensorowych dla CNN polega na zapisaniu danych w postaci tensorów, aby sieć mogła efektywnie analizować zależności przestrzenne lub sekwencyjne. Obrazy reprezentowane są najczęściej jako tensor $H \times W \times C$. Batch obrazów posiada dodatkowy wymiar N , określający liczbę próbek, co daje tensor $N \times H \times W \times C$.

Dane sekwencyjne zapisywane są jako tensory zawierające kolejne kroki czasowe sekwencji.



Schematyczny obraz architektury modelu konwolucyjnej sieci neuronowej (CNN) źródło: Jorgecardete, <https://medium.com/thedeephub/convolutional-neural-networks-a-comprehensive-guide-5cc0b5eae175>, 27.05.2026






Fig. 1. Visualization of a generated dataset consisting of 500005 points with 1536 dimensions, where each point represents an image generated with a generative adversarial network (GAN) method. The GAN model was trained using the ImageNet dataset. The figure illustrates the representation of these images using dimensionality reduction obtained by the execution of the simulated wide-warp t-SNE technique using principal component analysis as initialization. Each color represents a different class.


Meyer, B. H., Pozo, A. T. R., & Zola, W. M. N. (2022). Global and local structure preserving GPU t-SNE methods for large-scale applications. *Expert Systems with Applications*, 201, 116918.

Object Detection





Wydział
Biologii






2D Photogrammetry




Złożony obraz dna morskiego
Foto: Joseph Marlow & John Halpin




Images of underwater photogrammetric 3D models, showing textured mesh model of entire transect (a), machine-learning annotated mesh model of entire transect (b), focused textured mesh model (c), focused machine-learning annotated mesh model (d) and focused model of *Alcyonium digitatum* isolated from main model by colour (e). A copy of the photogrammetry model (obj. format) can be found in [Supplementary Material 2](#).

Marlow, J., Halpin, J. E., & Wilding, T. A. (2024). 3D photogrammetry and deep-learning deliver accurate estimates of epibenthic biomass. *Methods in Ecology and Evolution*, 15, 965–977. <https://doi.org/10.1111/2041-210X.14313>




Powierzchnia Jeziora Łebsko, wraz z wynikami klasyfikacji zbiorowisk - zaznaczonymi kolorami.




(a) Strappy



(b) Ferny



(c) Rounded



(d) Background

Fig. 8: Test dataset images with with correctly classified patches (where yellow = strappy, red = ferny, blue = rounded and pink = background).

R-CNN i Faster R-CNN



Wydział
Biologii

