



Wydział
Biologii

Wprowadzenie do głębokich architektur sieci neuronowych

Autoenkodery

Wykład nr 6


dr Mateusz Draga

Zakład Hydrobiologii

matdra@amu.edu.pl

Autoenkodery to typ sieci neuronowej należącej do uczenia nienadzorowanego, składającej się z enkodera i dekodera. Celem autoenkodera jest nauczenie się zwartej, bogatej informacyjnie reprezentacji danych o niższym wymiarze, która wciąż oddaje istotę oryginalnego wejścia. Ta skompresowana forma nazywana jest reprezentacją latentną lub wektorem latentnym, a przestrzeń, w której się znajduje, to przestrzeń latentna (znacznie mniejsza niż przestrzeń oryginalnych danych).

Enkoder przekształca dane wejściowe do niższego wymiaru, tworząc warstwę bottleneck, która zawiera skompresowaną reprezentację. Na jej podstawie dekodery możliwie wiernie odtwarza oryginalne wejście.




Schemat pracy Autoencodera.

Arden Dertat, <https://medium.com/data-science/applied-deep-learning-part-3-autoencoders-1c083af4d798> data dostępu 09.06.2026

<https://viso.ai/deep-learning/autoencoder/>

<https://medium.com/@divakar1591/autoencoders-6fab1a9a9f9c>

<https://medium.com/data-science/applied-deep-learning-part-3-autoencoders-1c083af4d798>




Schemat budowy Autoencodera.

Arden Dertat, <https://viso.ai/deep-learning/autoencoder/>,
data dostępu 09.06.2026

Zastosowania autoencoderów:

- redukcja wymiarów
- detekcja anomalii
- usuwanie szumu
- analiza danych sekwencyjnych
- generacja obrazów
- semantyczna segmentacja obrazów
- klasyfikacja obrazów




Autoenkodery, w przeciwieństwie do PCA, potrafią uchwycić nieliniowe zależności w danych. PCA sprowadza się do liniowej transformacji, czyli szuka kierunków największej wariancji w postaci prostych kombinacji oryginalnych cech. Dzięki warstwom aktywacji autoenkoder może modelować znacznie bardziej złożone struktury, znajdując kompresję, której żadna prosta linia nie byłaby w stanie opisać.

Redukcja wymiarów przeprowadzona przez PCA oraz liniowy Autoencoder. Zwróć uwagę na identyczność zgrupowania.

Michela Massi - Own work, CC BY-SA 4.0,

<https://commons.wikimedia.org/w/index.php?curid=80152034>. Data pobrania
09.06.2026.




Schemat budowy Autoencodera.

Gaudenz Boesch, <https://viso.ai/deep-learning/autoencoder/>, data dostępu 09.06.2026

Autoenkodery trenuje się w sposób nienadzorowany. Sieć uczy się odtwarzać dane wejściowe na wyjściu, minimalizując różnicę między oryginałem a rekonstrukcją.

Najczęściej stosowaną funkcją straty jest MSE (Mean Squared Error), która mierzy średnią kwadratów różnic między wartościami rzeczywistymi a odtworzonymi, wymuszając na sieci zachowanie najważniejszych informacji w reprezentacji latentnej. Dla danych binarnych stosuje się też Binary Cross-Entropy (BCE).



Warstwa latentna autoenkodera może być wykorzystana jako źródło cech (feature extraction) dla klasyfikatora CNN lub innej sieci neuronowej. Podczas treningu autoenkoder uczy się reprezentacji, która zachowuje najważniejsze informacje o danych wejściowych. Zamiast używać surowych danych, do klasyfikacji można wykorzystać właśnie wektor cech z warstwy latentnej.


Schemat budowy Autoencodera.

Gaudenz Boesch, <https://viso.ai/deep-learning/autoencoder/>, data dostępu 09.06.2026

Undercomplete Autoencoders




Wydział
Biologii



Undercomplete Autoencoder jest jednym z najbardziej podstawowych i najprostszych typów autoenkoderów. Na podstawie wprowadzanego obrazu próbuje odtworzyć pierwotny obraz. Jest też używany do generowania latent space, która może być później wykorzystany w różnorodnych celach.

Architecture of an undercomplete autoencoder with a single encoding layer and a single decoding layer.


Misra, S., Thakur, S., Ghosh, M., & Saha, S. K. (2020). An autoencoder based model for detecting fraudulent credit card transaction. *Procedia Computer Science*, 167, 254-262.



Sparse Autoencoding polega na takim trenowaniu autoenkodera, aby większość neuronów w warstwie ukrytej była nieaktywna (czyli ich aktywacje były bliskie zeru). W przeciwieństwie do undercomplete autoencoderów, nie ogranicza się on liczby neuronów w latent space, tylko wymusza rzadką aktywację poprzez regularizację (np. L1 lub KL-divergence). Dzięki temu model uczy się bardziej rozproszonych i znaczących reprezentacji cech danych. Sparse autoencodery są często wykorzystywane do ekstrakcji cech i uczenia reprezentacji w danych wysokowymiarowych.

Armaan A. Abraham, <https://www.lesswrong.com/posts/tLCBJn3NcSNzi5xng/deep-sparse-autoencoders-yield-interpretable-features-too>, data dostępu: 09.06.2026

Denoising Autoencoders



Schemat budowy Autoencodera.

<https://medium.com/@divakar1591/autoencoders-6fab1a9a9f9c>, data dostępu:

09.06.2026


Denoising Autoencoder jest typem autoenkodera, który uczy się odtwarzać oryginalne dane na podstawie ich zaszumionej wersji. W trakcie treningu do danych wejściowych celowo dodawany jest szum, a zadaniem modelu jest rekonstrukcja czystego sygnału. Dzięki temu autoencoder uczy się wychwytywać najważniejsze cechy danych i ignorować zakłócenia.

Oprócz usuwania szumu może być również wykorzystywany do generowania bardziej odpornych reprezentacji danych (latent space), które znajdują zastosowanie w dalszych zadaniach analitycznych i predykcyjnych.

Denoising Autoencoders




Wydział
Biologii




<https://iq.opengenus.org/denoising-autoencoders/>, data dostępu: 09.06.2026

Denoising Autoencoders




<https://iq.opengenus.org/denoising-autoencoders/>, data dostępu: 09.06.2026



Schemat budowy Autoencodera.


Gaudenz Boesch, <https://viso.ai/deep-learning/autoencoder/>, data dostępu 09.06.2026

VAE (Variational Autoencoder) to rozszerzenie klasycznego autoenkodera, które zamiast kodować dane jako pojedynczy punkt w przestrzeni latentnej, koduje je jako rozkład prawdopodobieństwa (średnią i odchylenie standardowe). Podczas treningu przestrzeń latentna jest wymuszana do przyjęcia regularnej, ciągłej struktury. Dzięki temu sąsiednie punkty w przestrzeni latentnej odpowiadają podobnym obrazom, a interpolacja między nimi daje sensowne wyniki. To pozwala na generowanie nowych danych przez próbkowanie dowolnego punktu z przestrzeni latentnej i przepuszczenie go przez dekodery.




Schemat budowy Autoencodera.

Gaudenz Boesch, <https://viso.ai/deep-learning/autoencoder/>, data dostępu
09.06.2026



Schemat budowy Autoencodera.


Gaudenz Boesch, <https://viso.ai/deep-learning/autoencoder/>, data dostępu
09.06.2026



Schemat budowy Autoencodera.

Ritwek, <https://viso.ai/deep-learning/autoencoder/>, data dostępu 09.06.2026

Convolutional Autoencoder



<https://datahacker.rs/020-overview-of-semantic-segmentation-methods/>, data dostępu 09.06.2026

Convolutional Autoencoder (połączenie CNN z autoenkoderem) polega na zastąpieniu warstw gęstych warstwami konwolucyjnymi w enkoderze i dekodерze. Enkoder CNN wydobywa lokalne cechy danych i kompresuje je do reprezentacji latent space, a dekodер odtwarza dane za pomocą warstw upsamplingu lub transposed convolution. Dzięki zachowaniu informacji przestrzennej takie modele są stosowane m.in. do kompresji i rekonstrukcji obrazów, usuwania szumu, wykrywania anomalii, a także jako część większych modeli w zadaniach klasyfikacji i segmentacji semantycznej.